

Proyecto 1. Tabaquismo y expresión génica en carcinoma oral de células escamosas

Entrega 1 - Diseño del proyecto

Estudiante: Javiera Canelo **Fecha de entrega:** 12 de septiembre

1. Pregunta y objetivo

¿Qué diferencias de expresión génica y vías biológicas se asocian al tabaquismo reportado en tejido tumoral de pacientes con carcinoma oral de células escamosas HPV-negativo?

El objetivo es explorar estas asociaciones mediante un workflow de RNA-seq y un análisis posterior en R. Se compararán tumores de pacientes con tabaquismo reportado como “yes” frente a “no”. Los resultados se interpretarán como asociaciones, sin atribuir causalidad ni establecer biomarcadores clínicos validados.

Justificación y relevancia biomédica

El tabaquismo es el principal factor de riesgo para el carcinoma oral de células escamosas (COCE), aunque se presenta tanto en personas fumadoras como no fumadoras. Comparar sus perfiles de expresión génica permite explorar si el tabaquismo reportado se asocia con diferencias en los procesos biológicos del tumor. Esto podría ayudar a formular hipótesis sobre mecanismos relacionados con proliferación, respuesta al daño celular o interacción con el microambiente tumoral.

Se seleccionan únicamente tumores HPV-negativos para mantener constante el estado viral y reducir una posible fuente de heterogeneidad biológica. La comparación se restringe, además, a la cavidad oral, distinguiéndola de la orofaringe, donde el papel del HPV es especialmente relevante.

Una motivación clínica es comprender si las diferencias moleculares podrían relacionarse con distintos comportamientos tumorales. Sin embargo, este proyecto no evaluará directamente agresividad, pronóstico ni respuesta al tratamiento. Los resultados permitirán generar hipótesis que requerirían validación con información clínica y cohortes mayores.

Dado el tamaño de cuatro pacientes por grupo y las diferencias de edad y sexo, el análisis tendrá carácter exploratorio y no permitirá atribuir causalidad al tabaquismo.

2. Dataset y diseño del estudio

Se utilizará **GSE184616**, disponible en GEO. Las lecturas originales están depositadas en SRA.

Característica	Descripción
Organismo	Homo sapiens
Enfermedad	Carcinoma oral de células escamosas HPV-negativo
Dataset completo	15 pacientes; 15 tumores y 15 tejidos normales adyacentes
Datos	Bulk RNA-seq de RNA total con eliminación de RNA ribosomal

Característica	Descripción
Secuenciación	Illumina NovaSeq 6000, paired-end y específica de hebra
Selección	Ocho tumores primarios de ocho pacientes independientes
Comparación	Cuatro pacientes con smoking = yes y cuatro con smoking = no
Archivos previstos	12 runs de SRA; 24 archivos FASTQ, correspondientes a R1 y R2
BioProject	PRJNA765370
Estudio SRA	SRP338257

Se excluyen los tejidos normales. Las mismas ocho muestras se utilizarán para el procesamiento y el análisis exploratorio de expresión diferencial.

3. Muestras seleccionadas y justificación


Muestra	GEO	Smoking original	Edad	Sexo	Sitio anatómico	Runs
OSCC_4-P	GSM5593754	Yes	48	Masculino	Piso de boca	1
OSCC_5-P	GSM5593756	Yes	22	Masculino	Lengua	1
OSCC_13-P	GSM5593772	Yes	37	Masculino	Lengua	3
OSCC_16-P	GSM5593776	Yes	42	Masculino	Lengua	1
OSCC_1-P	GSM5593748	No	50	Masculino	Lengua	1
OSCC_2-P	GSM5593750	No	33	Masculino	Lengua	1
OSCC_10-P	GSM5593766	No	46	Masculino	Lengua	1
OSCC_11-P	GSM5593768	No	50	Femenino	Piso de boca	3


Cada grupo incluye tres tumores de lengua y uno de piso de boca. Se mantiene así la misma distribución de estos sitios anatómicos. Las edades medias son 37,3 años en el grupo Yes y 44,8 años en el grupo No.


Se intentó equilibrar los grupos según sexo. Todos los pacientes con smoking = Yes de la tabla revisada son hombres. Solo hay tres hombres con smoking = No; por ello, la selección incluye una mujer en ese grupo.

4. Workflow previsto

Se desarrollará un workflow propio en **Nextflow DSL2**, usando nf-core/rnaseq como referencia de organización y buenas prácticas. No se ejecutará el pipeline completo de nf-core.







Decisiones de implementación

- **FastQC:** permitirá revisar la calidad de las lecturas originales. El trimming será una opción configurada tras revisar los reportes.
- **Trimming:** si se aplica, se documentarán la herramienta y los parámetros y se revisará la calidad posterior al recorte.
- **Agrupación:** los runs de OSCC_13-P y OSCC_11-P se reunirán por muestra, manteniendo correctamente asociados R1 y R2. Cada muestra producirá una sola cuantificación.
- **Salmon:** se utilizará para cuantificar transcritos. El índice y la correspondencia transcrito-gen procederán de una referencia y anotación compatibles.
- **MultiQC:** integrará los reportes y métricas compatibles de las herramientas. Constituye una rama de resumen de calidad, no una transformación de la matriz de expresión.
- **Reproducibilidad:** se fijarán versiones, referencias, parámetros y ambientes. Nextflow generará **report**, **timeline**, **trace** y **DAG**.

5. Samplesheet

El archivo `metadata/samplesheet.csv` contiene una fila por run. La repetición de `sample` identifica runs de la misma muestra, no pacientes adicionales. Las rutas son planificadas y relativas a la raíz del repositorio, los FASTQ aún no están descargados.

```
sample,run,fastq_1,fastq_2
OSCC_4-
P,SRR16013054,data/raw/SRR16013054_1.fastq.gz,data/raw/SRR16013054_2.fastq.
gz
OSCC_5-
P,SRR16013056,data/raw/SRR16013056_1.fastq.gz,data/raw/SRR16013056_2.fastq.
gz
OSCC_13-
P,SRR16013082,data/raw/SRR16013082_1.fastq.gz,data/raw/SRR16013082_2.fastq.
gz
OSCC_13-
P,SRR16013083,data/raw/SRR16013083_1.fastq.gz,data/raw/SRR16013083_2.fastq.
gz
OSCC_13-
P,SRR16013084,data/raw/SRR16013084_1.fastq.gz,data/raw/SRR16013084_2.fastq.
gz
OSCC_16-
P,SRR16013090,data/raw/SRR16013090_1.fastq.gz,data/raw/SRR16013090_2.fastq.
gz
OSCC_1-
P,SRR16013048,data/raw/SRR16013048_1.fastq.gz,data/raw/SRR16013048_2.fastq.
gz
OSCC_2-
P,SRR16013050,data/raw/SRR16013050_1.fastq.gz,data/raw/SRR16013050_2.fastq.
gz
OSCC_10-
P,SRR16013070,data/raw/SRR16013070_1.fastq.gz,data/raw/SRR16013070_2.fastq.
gz
OSCC_11-
P,SRR16013072,data/raw/SRR16013072_1.fastq.gz,data/raw/SRR16013072_2.fastq.
gz
OSCC_11-
P,SRR16013073,data/raw/SRR16013073_1.fastq.gz,data/raw/SRR16013073_2.fastq.
gz
OSCC_11-
P,SRR16013074,data/raw/SRR16013074_1.fastq.gz,data/raw/SRR16013074_2.fastq.
gz
```

6. Análisis posterior y resultados esperados

1. Importar las cuantificaciones con `tximport` y agregar la información de transcritos a genes utilizando una correspondencia compatible con la referencia de Salmon.
2. Integrar los datos con DESeq2 mediante su interfaz para tximport, conservando la información necesaria de longitudes efectivas. Filtrar genes de baja expresión y documentar el criterio.
3. Aplicar normalización y transformación VST para PCA y clustering; revisar muestras atípicas sin asumir que los grupos se separarán por tabaquismo.
4. Estimar expresión diferencial comparando Yes frente a No. Un log2 fold change positivo indicará mayor expresión en el grupo Yes. Se aplicará corrección por múltiples pruebas mediante FDR.
5. Evaluar enriquecimiento funcional a partir de genes ordenados por un estadístico del contraste, utilizando una colección documentada de vías o procesos biológicos.
6. Integrar calidad, efectos estimados, incertidumbre y resultados funcionales en un informe en R Markdown.

Limitaciones: cuatro pacientes por grupo, desequilibrio de edad y sexo, definición de exposición que debe verificarse y posible variación en la composición celular del tejido tumoral.

7. Repositorio y estado de desarrollo

Repositorio inicial: [javcanelo/cancer_oral_tabaco](https://github.com/javcanelo/cancer_oral_tabaco).

Ubicación	Contenido o función
README.md	Pregunta, dataset, selección, diseño y estado del proyecto
metadata/geo_all_runs.csv	Muestras y runs revisados del estudio
metadata/geo_selected_runs.csv	Metadatos de los runs seleccionados
metadata/samplesheet.csv	Entradas previstas para Nextflow
docs/workflow.md	Diagrama y decisiones de diseño
workflow/	Destino del código y configuración de Nextflow
analysis/	Destino de los scripts del análisis posterior

8. Fuentes de datos y referencia de diseño

- [GEO: GSE184616](#): descripción del estudio, muestras y metadatos.
- [SRA: SRP338257](#): lecturas originales y runs de secuenciación.
- [BioProject: PRJNA765370](#): proyecto asociado.
- [nf-core/rnaseq 3.14.0](#): referencia de diseño; no es el pipeline que se ejecutará.

La identificación de las muestras y los runs se basa en los registros de GEO/SRA revisados durante la preparación del proyecto. Las rutas del samplesheet representan la organización local prevista de las lecturas.