

Proyecto 1. Tabaquismo y expresión génica en carcinoma oral de células escamosas

Entrega 2 - Pipeline funcional de RNA-seq

Estudiante: Javiera Canelo **Fecha de entrega:** 29 de septiembre del 2026

1. Objetivo

Implementar y evaluar el workflow de procesamiento de RNA-seq definido en la Entrega 1, documentar su configuración, parámetros utilizados y resultados obtenidos con subconjuntos de prueba.

La evaluación comprende el control de calidad, el procesamiento de lecturas, la agrupación de runs por muestra, la cuantificación de transcritos y la integración de reportes. Su propósito es comprobar el funcionamiento técnico del pipeline antes del procesamiento de los datos completos y del análisis de expresión diferencial.

2. Datos de prueba

El proyecto contempla ocho muestras tumorales de GSE184616, correspondientes a 12 runs de secuenciación paired-end. Cuatro muestras presentan tabaquismo reportado como "yes" y cuatro como "no".

El desarrollo y evaluación del pipeline se realizó en 2 etapas:

1. **Prueba piloto sobre OSCC_4-P.** Se utilizaron los primeros 100.000 spots del run SRR16013054, obtenidos mediante SRA Toolkit. Se generaron 100.000 pares de lecturas de 150 bases. Este subconjunto permitió desarrollar el pipeline y luego probar el preprocesamiento.
2. **Prueba integrada sobre 8 muestras.** Posteriormente, para comprobar la ejecución del workflow con todos los runs seleccionados y la agrupación de las muestras con múltiples runs, se utilizaron los primeros 100.000 spots de cada uno de los 12 runs seleccionados. La entrada total fue de 1.200.000 pares de lecturas, distribuidos en 24 archivos FASTQ.

OSCC_11-P y OSCC_13-P tienen tres runs cada una, por lo que aportaron 300.000 pares iniciales por muestra. Las otras seis muestras aportaron 100.000 pares cada una. Los runs de una misma muestra se agruparon para obtener una única cuantificación por muestra biológica.

La prueba piloto se identificó mediante [metadata/samplesheet_test.csv](#) y la prueba integrada mediante [metadata/samplesheet_test_all.csv](#).

3. Implementación y configuración

3.1. Organización del workflow

El workflow se implementó en Nextflow DSL2 y se organiza en un flujo principal, un subworkflow de control de calidad y módulos por herramienta.

```
workflow/
├─ main.nf                # lectura del samplesheet e integración de las etapas
├─ subworkflows/
│   └─ control_calidad.nf  # conexión fastqc + fastp + fastqc_post_trimming
└─ modules/
    ├─ qc.nf               # fastqc (lecturas originales)
    ├─ trimming.nf         # fastp
    ├─ qc_post.nf          # fastqc (lecturas recortadas)
    ├─ salmon.nf           # cuantificación
    └─ multiqc.nf          # reporte integrado
```

El flujo `main.nf` lee el samplesheet (`sample,run,fastq_1,fastq_2`). FastQC inicial y fastp reciben las lecturas originales por run y pueden ejecutarse en paralelo. FastQC posterior recibe las salidas de fastp. Las lecturas procesadas se agrupan por muestra, conservando la asociación de R1 y R2 de cada run, y se entregan a Salmon.

Finalmente, MultiQC integra los reportes de FastQC, fastp y Salmon.




Figura 1. Grafo de procesos y dependencias del workflow integrado. El preprocesamiento se realiza por run y la cuantificación por muestra biológica.

3.2. Ambiente y versiones

La ejecución se realizó en el ambiente `oscc_rnaseq`, gestionado mediante micromamba y exportado en `environment.yml`. Las versiones registradas en `reportes/versiones.txt` fueron:

Herramienta	Versión	Uso
Nextflow	26.04.6	Orquestación del workflow
FastQC	0.12.1	Control de calidad
fastp	1.3.7	Trimming de adaptadores y polyG
Salmon	2.7.0	Cuantificación de transcritos
MultiQC	1.35	Integración de reportes

Se utilizó el perfil `local`, que ejecuta los procesos con las herramientas disponibles en el ambiente activo, sin contenedores.

3.3. Parámetros de preprocesamiento

fastp procesó conjuntamente R1 y R2, generando FASTQ pareados y reportes HTML y JSON. Se incorporó el recorte de adaptadores y polyG a partir de las señales observadas en la prueba piloto de OSCC_4-P.

Parámetro	Función
<code>--detect_adapter_for_pe</code>	Habilita la detección adicional de adaptadores paired-end, cuya presencia se observó en la prueba piloto
<code>--trim_poly_g</code>	Recorta colas polyG, detectadas especialmente en R2 del subconjunto piloto.
<code>--length_required 30</code>	Descarta lecturas menores de 30 bases después del recorte. Se utilizó como umbral inicial para excluir lecturas muy cortas; no se compararon otros valores.
<code>--thread 2</code>	Asigna 2 hilos para la ejecución local.
<code>--html</code> y <code>--json</code>	Genera reportes

Adicionalmente, se conservaron los filtros predeterminados de fastp. Una base se consideró de calidad suficiente a partir de **Q15** (`qualified_quality_phred = 15`) y se permitió hasta un 40% de bases inferiores a ese valor por lectura (`unqualified_percent_limit = 40`). Además se aceptaron como máximo 5 bases no

determinadas (`n_base_limit = 5`). Estos valores se utilizaron como configuración inicial, sin optimización específica para el conjunto completo de datos.

El comando no activó recorte de extremos mediante ventanas de calidad. Además, el umbral de longitud de 30 bases es inferior al tamaño de k-mer del índice de Salmon, de 31; por ello, conservar una lectura no garantiza que aporte evidencia útil a la cuantificación.

3.4. Referencia y cuantificación

La ejecución utilizó el índice local `reference/salmon_gencode_v50`, asociado al transcriptoma GENCODE v50. Se mantuvo la misma referencia para todas las muestras. El archivo de información del índice registra un tamaño de k-mer de 31 y ausencia de secuencias decoy; no se compararon configuraciones alternativas de indexación.

Parámetro	Función
<code>--libType A</code>	Permite inferir el tipo de biblioteca a partir de las lecturas y revisar su consistencia entre muestras. En la prueba se detectó <code>ISR</code> en las 8 muestras.
<code>--validateMappings</code>	Se incluyó para utilizar validación de los mapeos durante la cuantificación.
<code>--seqBias</code>	Se activó para considerar sesgos de secuencia en la estimación de abundancia.
<code>--gcBias</code>	Se activó para considerar sesgos asociados al contenido GC.
<code>--threads 2</code>	Asigna 2 hilos para la ejecución local.

No se realizaron comparaciones con y sin las correcciones de sesgo, por lo que no se atribuye una mejora cuantificada a cada opción individual.

Para las muestras con múltiples runs, se entregaron conjuntamente las listas de archivos R1 y R2 correspondientes, manteniendo el mismo orden entre ambas. De esta manera se obtuvo una cuantificación por muestra biológica, sin tratar los runs como réplicas independientes.

3.5. Recursos

Proceso	CPUs por tarea	Configuración adicional
FastQC inicial	2	Una tarea por run
fastp	2	Una tarea por run
FastQC posterior	2	Una tarea por run
Salmon	2	<code>maxForks 1</code> : una muestra a la vez
MultiQC	1	Un reporte integrado

Salmon se limitó a una tarea simultánea para controlar el uso de memoria RAM local. En la ejecución registrada, cada tarea alcanzó aproximadamente 3,2-3,5 GB de RAM.

4. Prueba piloto del preprocesamiento

La primera prueba se realizó con OSCC_4-P para comprobar la ejecución de FastQC, fastp y FastQC posterior, así como la generación de sus archivos de salida.

Métrica del subconjunto	Antes	Después
Pares de lecturas	100.000	92.769
Proporción de bases Q30	91,63 %	95,13 %
Longitud media reportada para R1 y R2	150 bases	131 bases

Se conservó el 92,77% de los pares. FastQC posterior mostró una disminución de la señal de adaptadores, aunque persistieron advertencias y fallos en otros módulos.

La prueba permitió comprobar el funcionamiento del preprocesamiento y observar su efecto sobre el subconjunto. Los parámetros se utilizaron posteriormente en la prueba integrada de los 12 runs. Estos resultados no constituyen una evaluación de la calidad de la biblioteca completa.

5. Prueba integrada del pipeline

5.1. Ejecución y registro de entradas

La prueba integrada utilizó `metadata/samplesheet_test_all.csv`, con los 12 runs de las 8 muestras seleccionadas.

El comando registrado para iniciar la ejecución fue:

```
bash scripts/ejecutar_pipeline.sh metadata/samplesheet_test_all.csv
```

El lanzador comprueba la disponibilidad de las herramientas, que el samplesheet exista y no esté vacío, y la presencia del archivo de información del índice de Salmon. Crea una carpeta de resultados, guarda una copia del samplesheet y las versiones utilizadas, y solicita los reportes de ejecución, tiempo y tareas de Nextflow.

La ejecución documentada se encuentra en `results/pipeline/20260928_121044/`.

5.2. Estado, duración y recursos

La ejecución finalizó con **45 tareas completadas**, sin tareas fallidas ni reintentos, en **22 min 48 s**. El reporte de Nextflow registró **0,9 horas de CPU**.

Proceso	Tareas	Duración por tarea	RAM máx. por tarea
fastqc	12	9,2–11,6 s	342–528 MB
fastp	12	9,3–12,7 s	1,2 GB
fastqc_post_trimming	12	8,7–12,3 s	384–505 MB
salmon_quant	8	1 min 42 s–4 min 55 s	3,2–3,5 GB
multiqc	1	10,3 s	238 MB

El preprocesamiento se desarrolló en aproximadamente 1 minuto. Salmon concentró la mayor parte del tiempo, con las muestras procesadas secuencialmente. Las muestras de un run requirieron alrededor de 2 minutos y las de tres entre 4-5 minutos.

5.3. Verificación de las salidas

La revisión de los archivos permitió comprobar las salidas esperadas de cada etapa:

Etapas	Salidas comprobadas
FastQC inicial	24 reportes HTML y 24 ZIP
fastp	24 FASTQ procesados, 12 reportes HTML y 12 JSON
FastQC post-trimming	24 reportes HTML y 24 ZIP
Salmon	8 archivos <code>quant.sf</code> , acompañados de métricas y logs
MultiQC	Un reporte HTML integrado y su carpeta de datos

Las 45 tareas se distribuyeron en 12 ejecuciones de FastQC inicial, 12 de fastp, 12 de FastQC posterior, 8 de Salmon y 1 de MultiQC.

En conjunto, fastp conservó **1.101.060 de los 1.200.000 pares iniciales**, equivalentes al **91,76%**. Los pares procesados se entregaron a la etapa de cuantificación.

5.4. Agrupación de runs y cuantificación por muestra

Para comprobar la conexión entre preprocesamiento y cuantificación, se comparó la suma de pares conservados por fastp con el número de fragmentos procesados por Salmon para cada muestra.

Ambos conteos coincidieron en las 8 muestras:

Muestra	Runs	Pares conservados por fastp	Fragmentos procesados por Salmon	Mapeo (%)
OSCC_4-P	1	92.769	92.769	73,23
OSCC_5-P	1	93.441	93.441	89,87
OSCC_13-P	3	277.384	277.384	84,69
OSCC_16-P	1	86.579	86.579	87,75
OSCC_1-P	1	92.124	92.124	83,66
OSCC_2-P	1	94.334	94.334	79,90
OSCC_10-P	1	91.099	91.099	89,37
OSCC_11-P	3	273.330	273.330	85,73

Además de los conteos, se revisaron las listas de entrada registradas por Salmon. OSCC_11-P y OSCC_13-P recibieron sus 3 runs con correspondencia entre R1 y R2, y cada muestra produjo una única cuantificación.

Las tasas de mapeo se incluyen como métricas de salida de la prueba. Sus diferencias no se interpretan como diferencias biológicas entre muestras o grupos, ni como una evaluación definitiva de las bibliotecas completas.

5.5. Integración de reportes

MultiQC incorporó:

- 48 reportes FastQC: 24 previos y 24 posteriores al procesamiento.
- 12 reportes fastp: uno por run.
- 8 resultados Salmon: uno por muestra.

Esto permitió comprobar que los reportes de las distintas etapas llegaron al módulo de integración y quedaron disponibles para su revisión conjunta.

5.6. Tamaño de los archivos

Los tamaños corresponden a los archivos locales de la prueba y se expresan en MiB.

Elemento	Tamaño
FASTQ de entrada: 24 archivos	156,65 MiB
Transcriptoma v50 comprimido	175,05 MiB
Índice de Salmon	1.976,64 MiB
Salida de fastp	148,49 MiB
FastQC inicial	22,56 MiB
FastQC posterior	22,22 MiB
Salmon: ocho muestras	251,58 MiB
MultiQC	20,50 MiB
Total de resultados, incluidos reportes y resúmenes	467,22 MiB

Estos valores describen el almacenamiento de la prueba. No permiten estimar directamente el espacio total que requerirá el procesamiento de las bibliotecas completas.

5.7. Trazabilidad y evidencia de ejecución

La ejecución documentada corresponde a [results/pipeline/20260928_121044/](#) . Se incluye una copia de sus reportes y archivos de identificación en [docs/evidencia_entrega_2/20260928_121044/](#) .

Las rutas de la siguiente tabla son relativas a esa carpeta de evidencia:

Archivo o carpeta	Contenido
reportes/samplesheet.csv	Copia de las entradas utilizadas
reportes/versiones.txt	Versiones de las herramientas
reportes/report.html	Estado general y uso de recursos
reportes/trace.tsv	Estado, duración y recursos por tarea
reportes/timeline.html	Distribución temporal de las tareas
multiqc/multiqc_report.html	Reporte integrado de las herramientas
multiqc/multiqc_report_data/	Datos y registros de MultiQC
resumen_entrega2/	Tablas de resumen de runs, muestras y tareas

La revisión de [report.html](#) y [trace.tsv](#) confirmó las 45 tareas completadas sin errores. El timeline permitió examinar el orden y la duración de los procesos, y el MultiQC permitió revisar conjuntamente las salidas a de las herramientas.

Los FASTQ y los archivos intermedios no forman parte de esta copia de evidencia.

6. Alcance y limitaciones

La evaluación comprobó la ejecución del workflow y la generación de sus salidas sobre subconjuntos pequeños. No evaluó su comportamiento con el volumen completo de datos.

La extracción de los primeros 100.000 spots de cada run no constituye un muestreo aleatorio. Además, las muestras con 3 runs aportaron más pares que las muestras con un solo run. Por ello, las métricas de calidad y mapeo se utilizan como evidencia técnica de la prueba y no para comparar las muestras biológicamente.

La finalización de las tareas sin errores tampoco implica que todos los módulos de FastQC deban estar clasificados como [PASS](#) . Las advertencias persistentes deberán interpretarse al revisar las bibliotecas completas.

En esta entrega no se realizó análisis de expresión diferencial ni enriquecimiento funcional.

7. Conclusión

El pipeline se evaluó primero mediante una prueba piloto sobre OSCC_4-P y posteriormente mediante una ejecución integrada de los 12 runs correspondientes a las 8 muestras seleccionadas.

La ejecución integrada completó las 45 tareas previstas y generó los reportes de preprocesamiento, 8 cuantificaciones y 1 reporte MultiQC. Se comprobó la agrupación de los runs por muestra y la coincidencia entre los pares conservados por fastp y los fragmentos recibidos por Salmon.

Estos resultados demuestran el funcionamiento técnico del workflow para los datos de prueba. El procesamiento de las bibliotecas completas y el análisis de expresión génica constituyen las siguientes etapas del proyecto.